

Univerzita Jana Evangelisty Purkyně
v Ústí nad Labem
Přírodovědecká fakulta



Tacit programming - návrh doménově
specifického jazyka a implementace jeho
interpretu

BAKALÁŘSKÁ PRÁCE

Vypracoval: Oleg Musijenko

Vedoucí práce: Mgr. Jiří Fišer, Ph.D.

Studijní program: Aplikovaná informatika

Studijní obor: Informační systémy

ÚSTÍ NAD LABEM 2024

Cíl bakalářské práce

Cílem bakalářské práce je ukázat výhody a nevýhody tacit přístupu k programování. Výstupem práce bude návrh vlastního doménově specifického jazyka (DSL), který bude využívat tacit programming, a navazující pilotní implementace jeho interpretu. Návrh jazyka by se měl soustředit na následující body:

- přehledná syntaxe,
- možnosti použití vysokoúrovňových nástrojů pro překlad a podporu běhu programu (např. LLVM v Haskellu) včetně parsování jazyka (např. Parsec v Haskellu),
- efektivita při vykonávání,
- případná podpora paralelních výpočtů

Prohlášení

Prohlašuji, že jsem tuto bakalářskou práci vypracoval samostatně a použil jen pramenů, které cituji a uvádím v příloženém seznamu literatury.

Byl jsem seznámen s tím, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., ve znění zákona č. 81/2005 Sb., autorský zákon, zejména se skutečností, že Univerzita Jana Evangelisty Purkyně v Ústí nad Labem má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle § 60 odst. 1 autorského zákona, s tím, že pokud dojde k užití této práce mnou nebo bude poskytnuta licence o užití jinému subjektu, je Univerzita Jana Evangelisty Purkyně v Ústí nad Labem oprávněna ode mne požadovat přiměřený příspěvek na úhradu nákladů, které na vytvoření díla vynaložila, a to podle okolností až do jejich skutečné výše.

V Ústí nad Labem dne 18. února 2024

Podpis:

Děkuji vedoucímu práce Mgr. Jiřímu Fišerovi, Ph.D.
za neocenitelné rady a pomoc při tvorbě bakalářské práce.

Též chci poděkovat své ženě, Anetě Musijenko,
za neustálou podporu během psaní práce.

Abstrakt

Cílem této bakalářské práce je vytvoření doménově specifického jazyka se zaměřením na konkurentní výpočty, který usnadní přehled business logiky a zlepší vývojářské prostředí (developer experience) se zaměřením na *tacit* - "beztečkové" paradigma. V práci se nachází ukázky, jak *tacit* programming vypadá a jsou zde vyzdvýženy argumenty proč psát programy *tacitně*. Ukázky v této práci potvrzují, že jazyky které nebyly primárně navrženy jako "beztečkové" umožňují v tomto stylu psát. Nadále se zde nachází obecné vysvětlení, jak prasovat jazyk pomocí knihovny Parsec a jak užít výsledek parsování do metaprogramming mechanismu "Template Haskell". Byly vytvořeny tři ukázky, které validují užití vytvořeného DSL. Nakonec se nachází do budoucna případné vylepšení DSL.

TACIT PROGRAMMING - NÁVRH DOMÉNOVĚ SPECIFICKÉHO JAZYKA A IMPLEMENTACE JEHO INTERPRETU

Klíčová slova

Abstract

TACIT PROGRAMMING - DESIGN OF A DOMAIN SPECIFIC LANGUAGE AND IMPLEMENTATION OF IT'S INTERPRETER

Translation of Czech abstract.

Key words

Translation of czech key words.

Obsah

Úvod	11
1 Programovací paradigma a tacit programming	13
1.1 Vysvětlení paradigmát	13
1.2 Vliv paradigmát na programovací jazyky	14
1.3 Tacit programming	14
1.4 Využití Tacit programmingu v různých programovacích jazycích	16
1.5 Debugging	18
1.6 Rešerše existujících implementací - APL	19
1.7 Kdy využít tacit zápis	20
1.8 Kdy se vyhnout tacit zápisu	20
2 DSL - principy a využití	23
2.1 Web a enterprise	23
2.2 Grafické DSL	23
2.3 Ostatní DSL	24
2.4 Problémy DSL	24
3 Návrh vlastního DSL	25
3.1 Vysvětlení gramatiky jazyka	26
3.2 Refactoring původního designu	27
3.3 Proč Template Haskell místo LLVM	28
4 Implementace interpretu navrženého DSL	29
4.1 Parsec a kombinátory	29
4.2 Lexer a hlavní datové typy	30
4.3 Parser	33
4.4 Testování	34
4.5 Z AST do Template Haskell	34
5 Ověření použitelnosti (testování funkčnosti, praktické příklady využití)	41
5.1 Využití při načítání 3D modelů a scén	41
5.2 Využití pro web scraping	44

5.3	Využití pro datovou analytiku a změření výkonu	46
5.4	Nedostatky a potenciální vylepšení do budoucna	47
6	Závěr	49
7	Citace	51

Úvod

V současnosti se vyrábí procesory s co největším počtem jader, a tím pádem i vláken, i přesto, že je velmi náročné pro jednu aplikaci tyto další vlákna využít. Objevují se zde často potíže se stavem programu, kde se musí daný stav šířit napříč různými vlákny. Proto cílem této bakalářské práce bylo vytvořit DSL, který má pomoci s pochopením přenosu dat mezi různými vlákny a vyřešit problémy spjaté s přenosem, což má za následek snazší přístup k dalším počítačovým zdrojům. Pro implementaci DSL byl využit programovací jazyk Haskell a v práci se nachází odůvodnění, proč byl tento jazyk zvolen.

V první kapitole se nachází vysvětlivka programovacích paradigmat a jak vypadá tacitní syntaxe, protože navržené DSL využívá tuto syntaxi. V druhé kapitole se nachází využití různých DSL v závislosti na kontextu projektu. Ve třetí kapitole se může čtenář dočíst, jak došlo k navržení DSL a v následující kapitole jak došlo k implementaci v jazyce Haskell. V předposlední kapitole se nachází tři praktické ukázky, jak lze takové DSL využít. V poslední kapitole jsou vytknuty nedostatky implementace a kde by mohlo dojít k vylepšení.

Před studováním této bakalářské práce se doporučuje znát základy funkcionálního programování a to konkrétně Haskellu. Nachází se zde příklady, které se srovnávají s jazykem C nebo JavaScriptem. Návrh je vytvořen v Haskellu pomocí knihoven jako jsou Parsec a MTL (Monad Transformer Library).

1 Programovací paradigma a tacit programming

Programovací paradigma je způsob myšlení a přístupu k návrhu, strukturování a implementaci počítačových programů. Definuje sadu pravidel, postupů, technik a konceptů, které určují způsob, jakým se programy píší a organizují. Paradigma poskytuje rámec pro definici a řešení problémů v programování.

Některé z nejznámějších programovacích paradigmat zahrnují procedurální, objektově orientované a funkcionální. Na různá paradigmat má zároveň vliv způsob správy paměti.

1.1 Vysvětlení paradigmat

Procedurální paradigma se zaměřuje na sekvenci instrukcí, které jsou vykonávány postupně v závislosti na architektuře procesoru. Program je rozdělen na procedury a funkce, které provádějí určité operace.

Objektově orientované paradigma klade důraz na objekty a jejich interakce. Program je strukturován kolem tříd, které obsahují data (atributy) a metody (funkce), které s těmito daty pracují.

Funkcionálního paradigma je deklarativní způsob programování, kde funkce jsou považovány za základní stavební bloky programu. Funkcionální jazyky mají za cíl minimalizovat vedlejší efekty. To přispívá ke stabilitě, zjednodušení problematiky domény a eliminaci některých typů chyb.

V různých funkcionálních jazycích je povolena různá míra mutace dat. Například jazyk F# umožňuje mutaci dat kdekoli v programu, což je částečně záměrem, aby uživatelé jiných programovacích jazyků měli snazší přenos svých vědomostí do nového prostředí. Na druhou stranu, v jazyce Haskell jsou mutace omezeny v IO monádě a data musí být uloženy ve specifických typech jako `IORef`, `STRef` nebo `MVar`. Takto Haskell pomáhá udržet jasnou separaci mezi čistým funkcionálním kódem a kódem, který se zabývá měnícím se stavem nebo interakcí s okolím.

Je důležité si uvědomit, že míra povolené mutace dat se může lišit mezi jednotlivými funkcionálními jazyky a je závislá na jejich návrhu a filozofii. Každý jazyk si volí kompromis mezi funkcionalitou a striktností v oblasti mutace, aby splňoval požadavky svých uživatelů a cílů, které si klade.

1.2 Vliv paradigmat na programovací jazyky

Velmi málo jazyků implementuje paradigma stoprocentně. Když to udělají, jsou takzvaně *čisté*. Je neuvěřitelně vzácné mít "čistě OOP" jazyk nebo "čistě funkcionální" jazyk. Mnoho jazyků má pár výjimek, například v OCamlu budete programovat pomocí funkcí 90% nebo více času, ale pokud potřebujete stav, můžete ho získat. I Haskell který se považuje za *čistě* funkcionální jazyk, tak podporuje *do* notaci díky němuž se dá psát kód imperativně. Dalším příkladem je že velmi málo jazyků implementuje OOP, jak si jej Alan Kay představoval (Toal, 2008). Mnoho jazyků usnadňuje programování v jednom nebo více paradigmat. V jazyce Scala můžete snadno provádět imperativní, objektově orientované a funkcionální programování. Pokud je jazyk úmyslně navržen tak, aby umožňoval programování v mnoha paradigmatech současně, nazýváme ho jazykem s více paradigmaty. Pokud jazyk neúmyslně podporuje více paradigmat, neexistuje pro to zvláštní slovo.

1.3 Tacit programming

Tacit programming je programovací styl, který klade důraz na kompozici funkcí, které manipulují argumenty a kde se tyto argumenty explicitně nespecifikují. Pro základní ukázky bude využit JavaScript jelikož se jedná o jeden z nejpobulárnějších jazyků. Základní principy funkcionálního a tacit programování jsou v jazyce JavaScript, jelikož se jedná o jeden z nejvíce pobulárních programovacích jazyků a v základu má již funkcionální možnosti. Detailnější principy jsou psány v Haskellu.

JavaScript

```
fetch("APIURL")
  .then(x => fancyFunction(x))
  .then(x => console.log(x))
  .catch(e => console.error(e))
```

Zde se řetězí funkce zpětného volání ("Callbacks"). Tento postup je běžný u JavaScript programátorů, ale bohužel má jednu malou nevýhodu. Tvoří se zde zbytečná anonymní funkce ("arrow function nebo-li šipková") a pokud bychom prohlubovali čím dál víc zásobník volání, mohou nám tyto anonymní funkce zabírat paměť a během debuggingu nám tento styl zápisu "znečišťuje" zásobník volání.

```
fetch("APIURL")
  .then(fancyFunction)
  .then(console.log)
  .catch(console.error)
```

Přepsaná ukázka je logicky ekvivalentní k té předešlé. Zásadní rozdíl je ten, že se nemusí na paměťový zásobník ukládat kontext anonymní funkce a explicitně se nepředávají parametry funkce. Tudíž se jedná o *tacit* zápis.

Následující úryvek ukazuje, jak funguje **currying** a proč souvisí s tacit programováním.

Javascript

```
const curry = (f) => a => b => f(a,b);
const sayHello = (a, b) => `Hello ${a} from ${b}`;
const applyToFunctionArray =
  (input,...args) => args.map(a => a(input))
const partiallyAppliedData = ["A", "B", "C"].map(curry(sayHello));
// [(b) => "Hello A from ${b}",
//  (b) => "Hello B from ${b}",
//  (b) => "Hello C from ${b}"]
const partiallyAppliedData2 = ["A", "B", "C"]
                              .map(curry(sayHello)(1));

// ["Hello A from 1",
//  "Hello B from 1",
//  "Hello C from 1"]
```

Curry funkce transformuje existující funkci tak, že máme pro každý argument vlastní vracející funkci. Z funkce **f(a,b,c,d)** vzniká funkce **f(a)(b)(c)(d)** (Kantor, 2019). V čem je toto výhodné? Například je zde uvedené pole, které se skládá z částečně aplikovaných funkcí. Takto může programátor naiterovat odpověď ze serveru do objektu z předchozí ukázky, které je závislé na třeba na uživatelském vstupu.

Zajímavější část je u *partiallyAppliedData2*. Curryovaná funkce vrací funkci, jež očekává vstupní parametr, aby byla vyhodnocena. Tento princip je důležitý pro lenivé vyhodnocení, který využívá Haskell.

Může zde padnout argument, že ve zmíněném případě se curryování nachází pouze pro funkci, která přijímá pouze dva argumenty. Zde je definice funkce, která převádí jakoukoliv funkci na curryovanou.

Javascript

```
const curry = (f) => (...args) => args.length >= f.length ?
  f.apply(this, args) : (...args2) =>
  curry.apply(this, args.concat(args2));
```

Nutné je zmínit, co **není** tacitní zápis. Řetězení metod nebo funkcí není jejich kompozicí! Z definice tacit programmingu vyplývá, že musí docházet ke kompozici funkcí bez specifikace parametrů a ne řetězit funkce v závislosti na jejich typu nebo prototypu.

C#

```
class MainClass
{
    static void Main(string[] args)
    {
        string someString = Foo("Some argument");
    }

    static string Foo(string arg)
    {
        return new StringBuilder(argument)
            .Append("Hello")
            .Append(" ")
            .Append("World")
            .ToString();
    }
}
```

Proč příklad se C# není zapsán jako tacit? Funkce *Append* vrací vlastní referenci na *StringBuilder* a ne novou funkci. Též se zde pracuje s argumenty funkce, což je proti definici tacit programmingu.

1.4 Využití Tacit programmingu v různých programovacích jazycích

Tacit programming se dá pouze využít v jazycích, které mají v sobě již zakomponované funkce jako hodnoty a anonymní funkce nebo-li lambda výrazy. Pokud jsou tyto podmínky splněné, tak lze obecně definovat funkci pro kompozici i přesto, že to nebude syntakticky kompaktní.

Následující příklad sumace:

Haskell


```
sumCustom:: (Traversable t, Num a) => t a -> a
sumCustom = foldr (+) 0
```

C

```
int sum(int* arr, size_t numOfElements)
{
    int acc = 0;

    for(int i = 0; i < numOfElements; i++)
    {
        acc += *(arr + i);
    }

    return acc;
}
```

Z příkladu si lze povšimnout, že beztečkový styl zápisu je opravdu kompaktní. V Haskellu není třeba explicitně manipulovat s parametry funkcí.

Další příklad poukazuje Fibonacciho posloupnost. **Haskell**

```
-- Haskell je lenivý jazyk a proto je možné vytvořit nekonečnou
-- fibonacciho posloupnost a z té si vzít jen potřebný počet čísel
fibonacci:: Num a => Int -> [a]
fibonacci = (flip take) fibonacciInfinite
    where
        fibonacciInfinite:: Num a => [a]
        fibonacciInfinite = scanl (+) 0 (1: fibonacciInfinite)
```

C

```
void fibonacci(uint* arr, size_t numOfElements)
{
    if(numOfElements > 0)
```

```
{
    arr[0] = 0;
}
if(numOfElements > 1)
{
    arr[1] = 1;
}
for(int i = 2; i < numOfElements; i++)
{
    arr[i] = arr[i - 1] + arr[i - 2];
}
}
```

Z pohledu imperativního programátora implementace v C je zcela jasná. Funkce přijímá ukazatel na pole a modifikuje toto pole. Zatímco v Haskellu tato implementace může být matoucí. Funkce `scanl` je velice podobná funkci `foldl`, jen místo konečného vracení akumulátoru, tak vrací průběžně vypočtené hodnoty.

1.5 Debugging

Debugging je zásadní činností při vývoji softwaru, která umožňuje identifikovat, analyzovat a odstraňovat chyby ve zdrojovém kódu. Proces debuggování je obzvláště důležitý v imperativních a objektově orientovaných jazycích, které často disponují vyspělými debugovacími nástroji. V těchto jazycích je očekáváno sekvenční vykonávání instrukcí, což usnadňuje postupné sledování jejich provádění. Inspekce zásobníku volání představuje další přirozenou součást debuggingu v těchto jazycích.

V případě lenivého jazyka Haskell však debugging přináší značné obtíže. Haskell využívá mechanismu lenivého vyhodnocování, což znamená, že hodnoty jsou vypočteny až ve chvíli, kdy jsou skutečně potřeba. Tato vlastnost komplikuje proces sledování výpočtu a identifikaci chyb. I přes existenci několika debuggovacích nástrojů pro Haskell může debugging pro zkušeného vývojáře představovat opravdovou výzvu. Zmatek může vznikat zejména při určování, kde a jak byla konkrétní proměnná získána, neboť její hodnota je vypočítána až v okamžiku, kdy je použita.

Naštěstí Haskell nabízí možnost využití REPL (Read - Eval - Print - Loop) prostředí, které umožňuje interaktivní evaluaci výrazů a postupné zkoumání jejich chování. REPL tak může sloužit jako užitečný nástroj pro rychlé testování a experimentování s funkcemi a výrazy. Přítomnost REPL v Haskellu zčásti kompenzuje obtíže spojené s debuggingem a poskytuje prostředí pro analýzu a ladění kódu.

1.6 Rešerše existujících implementací - APL

Jazyk APL je jazyk orientovaný na pole nebo-li *array oriented programming language* se syntaxí zaměřenou na tacit programming. V APL jsou všechny data reprezentovány jako pole a všechny pole jsou skládány ze skalárů a nad nimi jsou dělané matematické operace s poněkud netradiční syntaxí. Totiž každá předem jazykem definovaná funkce je přidělená ke speciálnímu UTF-8 charakteru. Například funkce pro přirozený logaritmus je '⊗' nebo zaokrouhlení nahoru či dolů jsou '⌈' '⌊'. Každá funkce se dá zapsat monadicky či dyadicky (Serrão, 2022).

Monadický zápis má argument operandu na pravé straně: `-5 ⍝ monadic`

Dyadický zápis má argumenty na obou stranách operandu: `10-7 ⍝ dyadic`

Jelikož všechny pole jsou tvořeny skaláry, tak operace "ignorují" strukturu pole a pracují přímo s obsahem pole.

```

    ⍲6           ⍝ 6 integers starting from the origin.
0 1 2 3 4 5
    1+⍲6       ⍝ Add 1 to the 6 integers starting from the origin.
1 2 3 4 5 6
    2×⍲6       ⍝ Multiply by 2 the 6 integers starting from the origin.
0 2 4 6 8 10

```

Pokud pole jsou u dyadického zápisu stejné délky, tak jsou hodnoty vypočteny jako jednotlivé skaláry.

```

    100 0 1 × 2 3 4
200 0 4

```

Operátory jsou vyhodnocovány z prava do leva.

```

    24 ÷ 12 6 - 4 2   ⍝ -> 24 ÷ 8 3
3 6

```

Zmíněné části kódu jsou vyjmuty z Serrão, 2022.

Booleany jsou reprezentovány jako 1 (True) a 0 (False). Zde je ukázka algoritmu, kde se sečte sekvence přirozených čísel (včetně nuly, ale při součtu nemá vliv), která jsou dělitelná buď třemi nebo pěti.

```

    Euler1 ← {+/{(0=3|ω)∨(0=5|ω)}/ω}

    Euler1 ⍲1000
234168

```

Funkce `(0=3|ω)∨(0=5|ω) ⍝ '|'` - modulo, `'=' is equal operator` zjišťuje zda-li je číslo dělitelné třemi nebo pěti a vrací 0 nebo 1. Operátor `/` funguje jako replicate (pokud je spojené s dalším operátorem, tak funguje jako reduce). Jelikož je vyhodnocování z prava do leva, tak pokud argument funkce je například 7 a 12 tak:

```
((0=3| 7 12)∨(0=10 | 7 12))/7 12 ⍝ Result: 12.
```

Toto celé funguje jako filtrování, kombinací operátorů `+/` se udělá suma výsledků.

Lze si ale povšimnout, že výše zmíněný příklad není zapsán v tacit stylu jelikož využívá argument `ω`. Je možné napsat zmíněný příklad do tacit stylu, ale zároveň se zvyšuje komplexita porozumění.

```
Euler1 ← +/((0=3|⍣)∨(0=5|⍣))×⍣
```

Euleroва implementace a pochopení psaní tacit stylu v APL pomohl článek (Tišnovský, 2022).

1.7 Kdy využít tacit zápis

Tacit styl může být mocný a elegantní. Zde je několik argumentů, proč by se měl tacit zápis využít:

Kompaktnost a elegance: Tacitní zápis může často zredukovat kód na mnohem kratší a elegantnější formu, což může zvýšit čitelnost a snížit objem psaného kódu.

Snížení chybovosti: Vzhledem k tomu, že tacitní zápis minimalizuje použití proměnných a stavu, může to snížit možnosti chyb spojených s nechtěnými efekty a nekonzistencemi v datech.

Výkonové optimalizace: V některých případech může tacitní zápis vést k efektivnějšímu kódu, protože se snižuje zbytečná manipulace s proměnnými a daty.

Snížení náročnosti na paměť: Tacitní zápis může minimalizovat požadavky na paměť tím, že eliminuje nutnost uchovávat mezivýsledky v proměnných.

Zvyšuje jasnost: V některých případech může tacitní zápis zvýšit jasnost kódu tím, že se soustředí na to, co se děje (funkce a operace), a minimalizuje odvádějící pozornost od proměnných a argumentů.

Kód s méně chybami: S minimálním množstvím stavových proměnných a nečekaných efektů může být kód napsaný v tacitním stylu méně náchylný k chybám.

Přenositelnost: Tacitní zápis může být často snadněji přenositelný mezi různými jazyky nebo platformami, protože se soustředí na základní funkce a operace.

1.8 Kdy se vyhnout tacit zápisu

Bohužel tacit styl také může být obtížný pro programátory, zejména pokud nejsou na tento způsob programování zvyklí. Zde jsou argumenty proti tacit stylu:

Složitost čtení a porozumění: Tacitní styl může být velmi těžko čitelný a obtížný k pochopení, což může způsobit problémy v týmu a při údržbě kódu. Programátoři by měli být schopni snadno rozumět kódu, který píšou, a kód napsaný v tacitním stylu může být matoucí.

Náročná údržba: I když může být výrazně kratší, kód napsaný v tacitním stylu může být obtížný k úpravám a opravám chyb. Programátoři, kteří nejsou zvyklí na tento styl, budou mít problémy s debugováním a vylepšováním kódu.

Nepodporované vývojářské prostředí: Některé programovací jazyky a prostředí nejsou vhodné pro zápis ve formě tacit, což může být dalším důvodem, proč by nemělo být programátorům vnucováno.

Ztráta flexibility: Tacitní styl může omezit flexibilitu programátorů při psaní kódu. Může být obtížnější provádět změny a úpravy v kódu, což může zpomalit vývoj.

Vzdělávací nároky: Programátoři, kteří nejsou obeznámeni s tacitním stylem, budou muset investovat čas a úsilí do jeho pochopení a osvojení. To může zpomalit vývojový cyklus a zvyšovat náklady na vývoj.

Nedostatek standardů: V různých programovacích jazycích mohou být různé konvence a standardy pro zápis ve formě tacit. To může způsobit nekonzistenci a zmatek mezi programátory.

Kompromisy na úkor čitelnosti: Někdy se programátoři mohou pokoušet dosáhnout krátkého kódu na úkor čitelnosti a jasnosti. To může vést k nepřehledným a těžko udržitelným programům.

2 DSL - principy a využití

DSL (Domain Specific Language) jsou jazyky, které se zaměřují na specifickou doménu problematiky. Obecně DSL jazyky jsou mnohem jednodušší než jejich plnohodnotné protějšky. Výhodou je, že náročnost učení je mnohem nižší než u GPL (General Purpose Language). Zároveň při potřebě expertů na specializovaný obor, nepotřebují znát detaily implementace algoritmů, ale místo toho pokud budou mít přístup rovnou k DSL - výpočet šikmosti stěny budovy, hodnota cukrů v krvi pacienta, tak mohou plnit svoji práci o mnohem efektivněji (Federico, 2021).

2.1 Web a enterprise

Jedním z nejrozšířenějších DSL jazyků je ze světa webu a to **HTML a CSS**. HTML se zaměřuje na vytvoření rámce pro zobrazení textu, zatímco CSS se zaměřuje na stylizaci webu pomocí DOM selectorů. Různé webové enginy renderují CSS jinak jelikož W3C standard neomezuje specifikaci všech selectorů. Jedním z takových příkladů je zpracování fontů.

Těž existují jazyky DSL, které jsou specifické pouze pro jednu danou enterprise aplikaci, kde její implementace často spočívá na bázi XML nebo podobného formátu jako je např. YAML. Zde DSL slouží například pro zjednodušení UI nebo business logiky. Třeba pro porovnání **XAML** pro .NET platformu zjednodušuje logiku, stylizuje UI a zároveň zbavuje potřeby tvoření "glue" kódu, který je vygenerován automaticky.

2.2 Grafické DSL

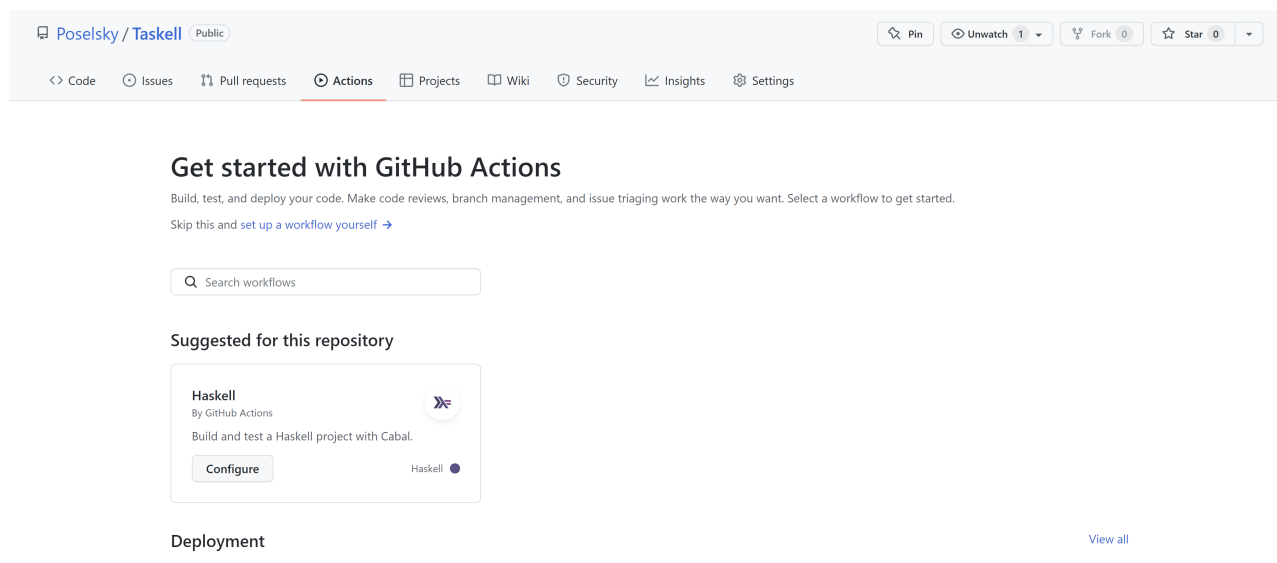
DSL se též týká programů co běží na grafických kartách. Renderovací programy jsou též známé pod pojmem *shader*. Každá grafická knihovna má vlastní DSL jazyk, který jsou velmi podobné jazyku C. Všechny renderovací jazyky prochází takzvanou *graphics pipeline*. OpenGL a Vulkan využívají pro rendering OpenGL Shading Language (GLSL). OpenGL kompiluje GLSL během runtime programu zatímco Vulkan využívá předkompilovaného GLSL bytecode nazývaný SPIRV.

Grafické karty se nevyužívají pouze pro rendering jelikož mají širokou škálu využitelnosti. Třeba *CUDA* vyvinutý firmou NVIDIA využívá dnešní architekturu grafických karet pro paralelní výpočet velkoobjemných dat, kde tuto techniku využívají dnešní algoritmy pro strojové učení.

2.3 Ostatní DSL

Další jazyk který je velice využíván v hardwarovém prostředí je **VHDL** nebo **Verilog**. Tyto DSL jsou zaměřené na simulaci obvodů pomocí FPGA (hradlových polí). Pro kompilaci projektů existuje **makefile** a je nejčastěji spárován s C/C++. Jsou zde DSL pro "continuous integration and deployment". Různé firmy co nabízejí online repositáře se v tomto budou trochu lišit, ale většina z nich poskytují jakousi formu automatizace vydání programu do oběhu. Toto poskytují firmy jako je GitHub, GitLab nebo Azure Dev Ops. Na GitHubu pomocí YAMLu se dají sepsat konfigurační soubory na testování a deployment.

Obrázek 2.1: Výstřižek z GitHub Actions



2.4 Problémy DSL

Každý projekt si vyžaduje čas, údržbu a dokumentaci. To se též týká DSL. Proto je velmi důležité zvážit, jestli je užitečné vytvořit DSL nad nějakou knihovnou. Opravdový problém nastává, když je potřeba dané DSL rozšířit nad rámec DSL a stává se z toho **Ghetto Language**. Na tuto problematiku naráží Martin Fowler ve své knize Domain Specific Languages. Člověk který udržuje dané DSL má za povinnost určit meze, kam bude projekt zasahovat. Totiž může nastat situace, kdy do DSL budou postupně implementovány podmínky, poté cykly a z ničeho nic existuje turingovsky kompletní jazyk, který je složitý na pochopení a údržbu. (Fowler et al., [c2011](#), s. 38-39)

3 Návrh vlastního DSL

Pro návrh DSL je klíčové vědět o jakou doménu problematiky se jedná. Častým problémem práce s konkurencí je, že je mnohdy náročné rozdělit data do jednotlivých transformací bez toho, aniž by programátoři vydali obrovské úsilí. Situace často přerůstá do komplexního problému, neboť je nezbytné porozumět, kde aplikovat semaforey a mutexy. V případě výskytu výjimky pak hledání místa, kde k výjimce došlo, může být vyčerpávající a nervydrásající, protože vlákna procesoru běží nezávisle na sobě, tak je tok dat vždy nedeterministický.

Představme si scénář z reálného života, na kterém si ukážeme nedeterminismus vláken. Tři lidé sdílejí domácnost a jeden má zaúkol uvařit knedlo vepřo zelo. Bohužel v lednici se nenacházejí žádné potřebné ingredience, a tak aby to bylo vůči všem stranám férové, zbylí dva členové domácnosti musí nakoupit. V blízkosti se nachází večerka a řeznictví, ale bohužel na opačných stranách ulice, tak pro urychlení se obě strany dohodnou, že se rozdělí na ušetření času. Zatímco jsou všichni pryč, kuchař si předpřipravil náčiní a ingredience ze spižírny. Aby si ušetřil čas, tak už dal vodu do kastrolu a nechal si předeřhát troubu. Mezitím se vrátil jeden člen domácnosti s vepřovou krkovicí, která byla okořeněna a dána do trouby. Po pár hodinách se vrátil zbývající člen se zbytkem nákupu, protože večerka je v neděli zavřená a další obchod je pár kilometrů daleko. Výsledkem celého vaření jsou knedlíky se spálenou krkovicí.

Dalo se tomu předejít, pokud by se o všechno postaral jeden člen domácnosti. Ale pokud jsou k dispozici další lidské zdroje pro urychlení práce, proč je nepoužít? Samozřejmě toto je celé jen pouze příklad, jak se může daný program s vícero procesory, který má zaúkol uvařit, chovat. Moderní programovací jazyky programátorům umožňují pracovat s jádry, ale nedeterministicky a mnohdy s velmi matoucím tokem dat.

Zatím neexistuje žádná DSL implementace pro konkurenci a paralelizaci vysokého objemu dat. Příkladem vysokého počtu dat je vzorek signálu a detailnější zpracování takového vzorku je časově velice náročné. Tato časová náročnost může být vyřešena právě zmíněnou konkurencí, či paralelizací problému. Toto DSL je pojmenované jako **Haskelyzer**. Pro řešení této problematiky byl zvolen Haskell, jelikož se zdá jako neoptimálnější pro rozbor jazyka, kde jsou komunitami vytvořené knihovny Parsec, MegaParsec a AttoParsec. Zároveň Haskell je navržen tak, že každá hodnota se chová jako konstanta, tudíž nemohou být pozměněny (kromě pár vyjímek), což dělá skvělého kandidáta na implementaci paralelních výpočtů. Obsahuje mechaniky tacit programmingu, je staticky silně typovaný a díky monádám, řešení okrajových případů jsou donucené GHC kompilátorem.

Hlubokou inspirací sloužila funkcionalita rozšíření "Arrows" v jazyce Haskell. Toto rozšíření umožňuje efektivnější propojení transformací dat. Ovšem, i když arrows přináší vylepšený zápis toku dat, narážíme na problém, kde samotný tok dat není zcela transparentní. Navzdory tomu, že arrows poskytují lepší zápis pro manipulaci s daty, není jasně oddělen od zbytku Haskell kódu. V jiných programovacích jazycích, jako je Python nebo F#, existuje také operátor pro předávání dat nazývaný "pipe", avšak v těchto jazycích slouží pouze k spojování dat bez dalších syntaktických ozdob. Pozoruhodným rysem těchto šipek je fakt, že jsou zapisovány tacitně.

3.1 Vysvětlení gramatiky jazyka

Původní návrh daného jazyka:

Haskelyzer

```
[CompileTime]
{
  let exampleCSV = "example.csv" :
    (a, Int)
    (b, Float)
    (c, String)
}

let concurrentProcess = exampleCSV | kalmanFilter
                                | gaussianFilter

let nestedConcurrentProcess = exampleCSV | kalmanFilter | sum
                                           | product
                                           | gaussianFilter
```

Na uvedeném příkladu je vidět, že jsou zde funkce deklarovány pomocí `let`. U `exampleCSV` myšlenka byla, že při zpracovávání vysokého objemu dat, tak často dochází k dlouhé prodlevě jen kvůli načtení. Atribut nad `exampleCSV` má 2 možnosti, `[RunTime]` a `[CompileTime]`. V obou případech se zkontroluje CSV soubor během kompilace, zda všechny datové typy souladí s předpisem. Rozdílem je, že v `[CompileTime]` atributu se CSV soubor stane součástí programu. Jednou z nevýhod této metody je, že při spuštění programu se zaplní paměť, protože obsah csv souboru je součástí samotného spustitelného programu. Nicméně díky tomu není nutné používat IO monádu a obsah csv souboru je k dispozici kdekoliv v programu. Při procesu kompilace se též

provádí kontrola, zda v csv souboru existuje dvojice "(a, Int)", kde "a" představuje název sloupce a všechny hodnoty ve sloupci "a" jsou typu "Int". To stejné platí pro ostatní dvojice, kde sloupec b má být typu Float a tak dále.

Pro vytvoření konkurentního výpočtu je zapotřebí využít *concurrent pipe composition* `|` operátoru. Každý další `|` vytváří další vlákno na kterém je prováděný výpočet. Celá syntaxe je závislá na odsazení, tudíž všechny `|` musí mít stejné odsazení.

Funkce *concurrentProcess* vytvoří funkci typu `IO ([a],[b])` a předpokládá, že v programu jsou definované a implementované funkce `kalmanFilter:: CSV -> [a]` a `gaussianFilter:: CSV -> [a]`. Výsledné IO monádě se nelze vyhnout, jelikož se jedná o konkurentní proces, kde vznikají vlákna v jež jsou provedeny výpočty.

Příklad s funkcí `let nestedConcurrentProcess` ukazuje, že *pipe operátory* se dají vnořovat. To znamená, že funkce `sum` i `product` musí mít typ

```
sum:: (Num a, Num b) => [a] -> b . Výsledná funkce bude vygenerována jako typ
concurrentProcess:: (Num a, Num b) => IO((a,b), [c]) .
```

3.2 Refactoring původního designu

Během implementace DSL se zjistilo, že vložení CSV souborů do kompilovaného programu se nehodí kvůli náročnosti na paměť a zároveň je zde nevýhodou když je potřeba změnit soubor s daty. Též došlo k zjištění, že DSL se nemusí pouze využít na analýzu dat, ale může se použít pro obecné manažování konkurentních procesů.

Haskelyzer

```
let guiMainLoop = | gatherMainState -> writeEventQueue -> render
                  | gatherEventQueue -> fireEventsToMainState
```

Pokud se jedná o GUI aplikaci, tak v GUI aplikacích se vždy nachází hlavní cyklus, který má zaúkol zpracovat uživatelské akce a vykreslit stav programu. `let guiMainLoop` je příkladem, jak takový hlavní cyklus může vypadat. Nedílnou součástí GUI aplikací je stav aplikace a *EventQueue*, kde se zaznamenávají všechny interakce uživatele a program může s těmito interakcemi pracovat. Jedním z důvodů proč sbírání uživatelských akcí na jiném vlákně je, že pokud by celý program běžel pouze na jednom procesoru, tak některé uživatelské akce mohou bránit vykreslování a tím by docházelo k zasekáváním programu. Například přehrávání zvuku musí běžet na jiném vlákně, protože jinak by se program vyrendroval poté, až by se dokončilo přehrávání zvuku.

3.3 Proč Template Haskell místo LLVM

Prvopočáteční implementace zahrnovala využití knihovny LLVM, která má za následek převzít AST a převést tento jazyk do LLVM *intermediate representation* (IR) (Lattner, 2008). Bohužel LLVM je knihovna primárně pro tvoření generických programovacích jazyků, než na tvoření DSL. DSL se dá pomocí této knihovny vytvořit, ale pro každou vygenerovanou funkci se musí vytvořit binding mezi IR a jazykem C, který je kompilován pomocí CLANG compileru a Haskelllem. Toto řešení je rozhodně možné, ale zvyšuje to komplexitu projektu a jednotlivé bindings mohou též být zdrojem nechtěných bugů. Proto se sešlo od implementace pomocí LLVM a místo toho ho nahradil mechanismus metaprograming Template Haskell.

4 Implementace interpretu navrženého DSL

Návrh jakéhokoliv DSL (a nejen DSL, ale i programovacího jazyka celkově) zahrnuje **Lexer**, **Parser** a **Abstraktní syntaktický strom (AST)**.

Lexer má za úkol přečíst soubor a najít jednotlivé tokeny v daném souboru. Tyto tokeny mohou obsahovat metadata, jako jsou řádek a sloupec, kde se token nachází, jaký token předcházel a jaký následuje atd... Tyto tokeny jsou zpracovány **parserem**, který má za úkol přečíst tokeny a hledat mezi nimi dle předem definované gramatiky vztahy a zpracovat je do abstraktního syntaktického stromu. AST je výsledek parsování a obsahuje všechny definice jazyka.

4.1 Parsec a kombinátory

V tradičních imperativních jazycích parsování probíhá pomocí načtení souboru do takzvaného *streamu* a poté se ze streamu načítají jednotlivé znaky na zpracování tokenů. Stream se používá z důvodu konzumace paměti, kde každý stream může být naimplementován jinak. Díky Haskell knihovnám jako je Parsec, AttoParsec nebo Megaparsec, není potřeba zpracovávat jednotlivé znaky, ale stačí definovat kombinátory, které tyto tokeny vrací. Haskelyzer využívá knihovnu Parsec. Zde je následující příklad primitivního kombinátoru.

```
import qualified Text.Parsec.Token as Tok
type CustomParser a = Parsec String () a

data Variant = Double | Integer | String deriving Show

emptyLexer :: Tok.GenTokenParser String () Identity
emptyLexer = Tok.makeTokenParser Tok.emptyDef

integer :: CustomParser Variant
integer = Tok.integer emptyLexer
```

```
float :: CustomParser Variant
float = Tok.float emptyLexer

parseToVariant :: CustomParser [Variant]
parseToVariant = many $ integer <|> float <|>
  (lexeme $ (manyTill alphaNum $ try space))
```

Cílem výše zmíněného příkladu je, přečíst soubor do `String` a rozparsovat ho na list, který obsahuje 3 různé datové typy a to na *integer*, *double* nebo *string*. Typový synonym `CustomParser a` je synonym pro `Parsec String () a`, což znamená, že Parsec čte soubor do streamu typu `String`, kde nemá žádný stav nebo-li prázdný tuple `()`. Parsec je *Monad Transformer*, který zároveň má v sobě zahrnutou stavovou monádu a po úspěšném parsování vrací typ `a`.

Je nutné zmínit funkci `parseToVariant`. Díky kombinačnímu operátoru `<|>` lze pouze definovat vysokoúrovňovou parsovací logiku bez potřeby manipulace jednotlivých tokenů. Tento operátor funguje na bázi **alternativa** nebo **fallback**. Pokud selže parser integer, tak se pokusí parsovat float, pokud i ten selže, tak vždy se rozparsuje poslední možnost a tou je jakýkoliv text.

4.2 Lexer a hlavní datové typy

Na začátek je důležité si nadefinovat hlavní datové typy, které budou sloužit jako výsledek parsování. Parsec zprostředkovává jednoduchý token parser, který definuje komentáře, operátory a rezervovaná jména. Haskelyzer využívá takzvaný *lexeme* parser. Tento druh parseru má za úkol ignorovat veškeré whitespace tokeny jako jsou například tabulátory, jednoduché mezery nebo nové řádky. Díky tomuto druhu parseru se může vývojář pouze soustředit na jednotlivé tokeny. Naneštěstí knihovna Parsec má v sobě nevyřešené bugy v *lexeme* funkcionalitě, které se nemohou opravit, protože by se mohly zničit již existující parsery, které jsou budovány kolem těchto bugů. Tento problém není ani správně dokumentován a proto se doporučuje místo knihovny Parsec, využít v nových parserech knihovnu MegaParsec nebo AttoParsec.

Definice lexeru si vyžaduje nakonfigurovat jednotlivé parametry, jako je senzitivita velkých a malých písmen, komentáře a rezervovaná jména.

```
haskelyzerLexer :: Tok.GenTokenParser String () (IndentT Identity)
haskelyzerLexer =
  Tok.makeTokenParser Tok.emptyDef
  {
    Tok.commentStart = "#{",
```

```

Tok.commentEnd = "}",
Tok.commentLine = "##",
Tok.reservedOpNames = ops,
Tok.reservedNames = names,
Tok.identStart = letter,
Tok.identLetter = letter,
Tok.opStart = oneOf " !#$%&*+./<=>?@\\^|_~",
Tok.opLetter = oneOf " !#$%&*+./<=>?@\\^|_~",
Tok.nestedComments = True,
Tok.caseSensitive = True
}
where
ops = ["+", "*", "-", ";", "->", ":", ",", "|"]
names = ["let"]

```

Lze si všimnout, že tato funkce má poněkud zajímavý typ `IndentT Identity`. Jelikož jazyk nepoužívá středníky a místo toho využívá jednotlivá odsazení, tak se zde využívá pomocný monad transformer `IndentT` z knihovny *indents*. Díky tomu není nutné manuálně počítat jednotlivá odsazení, protože budou automaticky započteny v záslosti na zdroji.

Pokud navrhovaný DSL obsahuje nějaké binární či unární operace, tak je zapotřebí si definovat do základních stavebních bloků lexeru.

```

data BinOp
= Plus
| Minus
| Times
| Divide
deriving (Eq, Ord, Show)

data UnaryOp
= Not
| Nroot -- Like SquareRoot but N
| Exponent
deriving (Eq, Ord, Show)

type OptionalColumnNameWithType = (Maybe String, CsvDataType)
data Schema = Schema VarNamePath [OptionalColumnNameWithType]

```

```
deriving (Show, Eq, Ord)

data Expr
  = BinOp BinOp Expr Expr
  | CsvDataType CsvDataType
  | UnaryOp UnaryOp Expr
  | Var Name [HaskelyzerFunction]
  | SchemaExpr Schema
  | LiteralExpr Literal
  deriving (Eq, Ord, Show)

data HaskelyzerFunction =
  HaskelyzerFunction Name [Name] -- Function name args
  | Concurrent [[HaskelyzerFunction]]
  deriving (Show, Ord, Eq)

data CsvDataType =
  CsvFloat
  | CsvInt
  | CsvString
  deriving (Show, Ord, Eq)

data Literal =
  Float Double
  | Int Integer
  | String String
  deriving (Show, Ord, Eq)
```

`[Expr]` je co tvoří AST. Seznam jednotlivých `expression` je hlavní datový typ všech DSL.

Data `Literal` jsou pouze primitivní datové typy stejně jako `CsvDataType`, rozdílem je že `CsvDataType` předem definuje, zda-li všechny sloupce v CSV souboru jsou očekávaným datovým typem.

Typ `OptionalColumnNameWithType` je pro CSV soubory, kde CSV soubor má možnost mít záhlaví a `data Schema` ukládá tuto informaci včetně cesty k tomuto souboru.

Haskelyzer podporuje vnořené funkce. Pro podporu této vlastnosti `HaskelyzerFunction` musí být rekurzivní, protože `HaskelyzerFunction` může nabrat formu

```
Concurrent [[Concurrent [[HaskelyzerFunction "Foo" []]]]]
```



```
,[HaskelyzerFunction "Fun" ["arg1"]]]].
```

První část `HaskelyzerFunction` je pouze funkce a její argumenty, druhá část je `Concurrent` `[[Haskel`.
Ve výše zmíněných příkladech bylo poukázáno, jak každá vygenerovaná funkce může vytvořit další konkurentní funkce a v nich další vnořené konkurentní funkce. Díky této vnořenosti je potřeba uchovávat funkce v listu listů.

`Var Name [HaskelyzerFunction]` vygeneruje funkci s názvem "Name" a pořadí funkcí v `[HaskelyzerFunction]` určují, v jakém pořadí budou funkce aplikovány, v tomto případě jsou aplikovány zleva do prava.

4.3 Parser

Zpočátku se určí tabulka operátorů a v jakém pořadí se operátory aplikují, poté se tato tabulka předá nultému výrazovému parseru, kde tento parser dokáže rozpoznat zda-li výraz patří mezi hlavní výrazy. Zároveň se pro zjednodušení zápisu se definuje typový synonym pro parser.

```
binary s f assoc =
    Ex.Infix (reservedOp s >> return (BinOp f)) assoc

table = [[binary "*" Times Ex.AssocLeft,
           binary "/" Divide Ex.AssocLeft]
         ,[binary "+" Plus Ex.AssocLeft,
           binary "-" Minus Ex.AssocLeft]]

type IParser a =
    IndentParser -- Indent monáda z knihovny indent
    String       -- Vstupní typ, může zde být i Text nebo ByteString
    ()           -- Stav, v tomto případě stav není zapotřebí
    a            -- Vracející typ po úspěšném parsování

expr :: IParser Expr
expr = Ex.buildExpressionParser table factor

factor :: IParser Expr
factor =
    try schemaParser
    <|> try variableParser
    <|> parens factor
```

```
toplevelP :: IParser [Expr]
toplevelP = do
    def <- many $ do
        try $ many newline
        s <- expr
        try $ many newline
        return s
    eof
    return def

parseToplevelP :: String -> Either ParseError [Expr]
parseToplevelP input =
    runIndent $ runParserT toplevelP () "<stdin>" input
```

Funkce `parseToplevelP` je hlavní vstup pro parsování obsahu, který vrací **AST**. Jelikož typ `[Expr]` je zároveň rekurzivní, tak tvoří strom - **AST**.

4.4 Testování

Bez testování parseru by nevznikl žádný spolehlivý parser, což dělá testovací fázi jakousi nutností. S každou přidanou větví parseru musí být přidaná další část v testování, kterou tuto větev prošetří. Logika testování parseru stojí pouze na tom, že se předá jednoduchý vstup ve formě řetězce nebo souboru a předpokládá se, že výstup parsování bude identické jako předem definované AST. V testovací fázi se hodí též přidat i vyjímky, které by měli parsování selhat.

4.5 Z AST do Template Haskell

Template Haskell je rozšíření Haskellu od verze 6, který umožňuje typově bezpečné meta-programování během kompilace. Tím se otevírají možnosti vytvořit funkcionality, kde program se může modifikovat sám sebe, čemuž se říká **reflekce**. Pro tvorbu Haskelyzeru je Template Haskell nedílnou součástí, bez které se nedá obejít. Je též možné vytvořit výstupní soubor s vygenerovaným Haskell kódem a jej následně umístit do jednotlivých modulů, ale to nezaručuje, že vytvořený program bude typově bezpečný. Pokud by se chtěla zaručit tato bezpečnost, tak by se vygenerovaný kód musel projít přes Haskell interpreter z knihovny Hint. Čtenář může usoudit, že toto celé je nepotřebně komplexní a že je výrazně snazší využít již existujících meta-programming funkcionalit.

V tuto chvíli jsou zde pouze limitované funkcionality. Z AST se nyní generují pouze curryované

funkce, kde všechny koncové funkce musí vracet stejný datový typ.

Zde je příklad, kde `loadModel1` a `loadModel2` nemusí mít stejný počáteční datový typ, ale koncové funkce jako je `scale` vrací stejný datový typ `a`.

Haskelyzer

```
let loadModels =
| loadModel1 -> rotate 0.0 45.0 90.0 -> scale 4.0
| loadModel2 -> translate 60.0 0.0 0.0 -> scale 3.0
```

Při překladu z AST se vygeneruje během kompilace tato funkce.

Haskell

```
loadModels :: IO [Model]
loadModels = runListConcurrently [_loadModel1, _loadModel2]
  where
    _loadModel1 =
      ((scale 4.0) . (rotate 0.0 45.0 90.0)) loadModel1
    _loadModel2 =
      ((scale 3.0) . (rotate 0.0 45.0 90.0)) loadModel2
```

Toto je složitější než se na první pohled zdá, protože celý kontext této funkce se může změnit v ten moment, kdy se začlení parametry funkce.

Haskelyzer

```
let loadModels scaleFactor =
| loadModel1 -> rotate 0.0 45.0 90.0 -> scale scaleFactor
| loadModel2 -> translate 60.0 0.0 0.0 -> scale scaleFactor
```

Haskell

```
loadModels :: Float -> IO [Model]
loadModels scaleFactor =
  runListConcurrently [_loadModel1, _loadModel2]
  where
    _loadModel1 =
      ((scale scaleFactor) . (rotate 0.0 45.0 90.0)) loadModel1
```

```
_loadModel2 =  
    ((scale scaleFactor) . (rotate 0.0 45.0 90.0)) loadModel2
```

Prvně se definuje soubor, kde se Haskelyzer nachází, tento soubor se označí jako modul pro kompilátor, protože veškeré změny v souboru se musí překompilovat. Výstup funkce je `[Decl]` obalený `Quasi Quotes` – `Q` monádou.

Nadále se AST zpracuje do jednotlivých, kompilátorem podporovaných, Haskell funkcí.

Haskell

```
generateHaskalyzer:: FilePath -> Q [Dec]  
generateHaskalyzer filePath = do  
    absoPathTkl <- runIO $ makeAbsolute filePath  
    addDependentFile absoPathTkl -- recompile on file change  
    -- enable printing during compilation  
    runIO $ hSetBuffering stdout NoBuffering  
    runIO $ hSetBuffering stderr NoBuffering  
  
    ast <- runIO $ readFile filePath >= parseTopLevelP  
    case ast of  
        Right exs -> mapM astExprToDec exs  
        Left pe -> error $ show pe  
  
astExprToDec:: Expr -> Q Dec  
astExprToDec (Var n args haskFunctions) = do  
    let name = mkName n  
    liftIO $ print haskFunctions  
  
    -- generate uncapturable names which are not global  
    argsAsVarP <-  
        mapM (\x -> do y <- newName x; return (x, y)) args  
  
    let argsMap = Map.fromList argsAsVarP  
  
    haskFunctionsAsExp <-  
        mapM (haskelyzerFunctionToExpr argsMap) haskFunctions  
    let result =  
        FunD  
            name
```

```

    [
        Clause
            (map (VarP . snd) argsAsVarP)
            (NormalB $ composed haskFunctionsAsExp)
            []
    ]
]
liftIO $ print $ pprint result
return result
where
    composed :: [Exp] -> Exp
    composed (fa:fb:fs) = let composeName = mkName "." in
        foldl
            (\acc x ->
                InfixE
                    (Just x)
                    (VarE composeName)
                    (Just acc))
            (InfixE (Just fb) (VarE composeName) (Just fa))
            fs
    composed [fa] = fa
    composed [] = error "Variable can't be empty"

composeHaskelyzerFunction ::
    Map String Name -> [HaskelyzerFunction] -> Q Exp
composeHaskelyzerFunction knownArgumentsMap [] =
    error "Can't compose empty list"
composeHaskelyzerFunction knownArgumentsMap (f:fs) = do
    hf <- haskelyzerFunctionToExpr knownArgumentsMap f
    foldrM helper hf fs

where
    helper x acc =
        let f = haskelyzerFunctionToExpr knownArgumentsMap x
        in
            f >=> \a -> return $ UInfixE a (VarE '($)) acc

haskelyzerFunctionToExpr ::
    Map String Name -> HaskelyzerFunction -> Q Exp
haskelyzerFunctionToExpr

```

```
knownArgumentsMap
(HaskelyzerFunction name args) = do
  -- Get variables from local parameters,
  -- if none exist use global ones
  createdArguments <-
    foldrM
      (\arg acc ->
        let val = knownArgumentsMap Map.!? arg in
        case val of
          Nothing -> return (mkName arg:acc)
          Just x -> return (x:acc) else
      )
      []
      args

  let varsP = map VarP createdArguments
  let fName = mkName name

  return ( functionApplicationE fName createdArguments )
  -- return (LamE varsP )

where
  functionApplicationE :: Name -> [Name] -> Exp
  functionApplicationE functionName (n:ns)=
    foldr
      (\x acc -> AppE acc (VarE x) )
      (AppE (VarE functionName) (VarE n))
      ns
  functionApplicationE functionName [] =
    VarE functionName

haskelyzerFunctionToExpr knownArgumentsMap (Concurrent fs) = do
  composedFunctions <-
    mapM (composeHaskelyzerFunction knownArgumentsMap) fs
  AppE (VarE 'runListConcurrently) $ ListE composedFunctions

runListConcurrently :: [IO a] -> IO [a]
runListConcurrently = mapConcurrently id
```


5 Ověření použitelnosti (testování funkčnosti, praktické příklady využití)

S rozšiřujícím se kódem a funkcionalitou projektu se zvyšuje obtížnost určení, kde se nachází problém a jak jsou data distribuována v daném systému. Jednou z nejkomplicovanějších výzev při psaní softwaru je jeho škálovatelnost. Haskelyzer má výhodu oproti tradičnímu způsobu psaní kódu v tom, že nejkritičtější části kódu jsou odděleny od business řešení a nabízejí širší pohled na tok dat. To může být z jedním hlavních argumentů, proč toto DSL využít pro větší projekty, protože usnadňuje jeho škálování. Vývojáři mají možnost určit, které části jsou nejdůležitější pro daný cíl a zapsat je do Haskelyzeru.

Konkurence má výhodu v tom, že obecně zvyšuje škálovatelnost softwaru, ale zároveň přináší složitější stav a zvyšuje riziko výskytu chyb. Haskelyzer není pouze DSL pro vnější zápis kritických částí softwaru, ale také umožňuje zápis konkurentních výpočtů v snadno čitelné formě. Tím vzniká určitá forma samo-dokumentace, kterou lze statickým jazykovým analyzátozem převést do UML zápisu.

5.1 Využití při načítání 3D modelů a scén

Skvělým příkladem, kde se dá využít konkurence je při načítání scén. Scény jsou tvořeny 3D modely, které mohou být komplexní a dlouhé a proto jejich parsování může zabrat hodně času. Pro tento příklad byl zvolen vedlejší projekt, který má za úkol vyrenderovat 3D modely pomocí knihovny OpenGL, WaveFront a Lens.

Knihovna Lens vygeneruje pomocí Template Haskell gettery a settery. Pomocí těchto vygenerovaných vlastností se dá jednoduším způsobem dostat ke vnořeným vlastnostem dat. Třeba operátor (`%~`) neboli `'over'` přijímá data, jméno vlastnosti a funkci která transformuje pouze danou vlastnost dat.

Vysvětlení samotného rendereru je mimo rozsah této práce, stačí pouze vědět, že je zapsán pomocí OpenGL, jelikož tato grafická knihovna nemá podporu pro multithreading a renderuje 3D modely ve Wavefront formátu, tak dané modely se musí načíst, rozparsovat a poté vyrenderovat na hlavním vlákne.

Haskell

```
data LoadedWaveFrontOBJ = LoadedWaveFrontOBJ {  
  -- WaveFrontOBJ from https://github.com/phaazon/wavefront  
  _loadedWaveFrontOBJWaveFront :: WaveFrontOBJ  
  , _loadedWaveFrontOBJScale     :: GL.GLfloat  
  , _loadedWaveFrontOBJTranslate :: Linear.V3 GL.GLfloat  
  , _loadedWaveFrontOBJRotation  :: Linear.Quaternion GL.GLfloat  
} deriving Show  
  
$(makeLenses 'ObjectDescription)
```

Haskelyzer

```
let loadModels =  
| loadModel1  
| loadModel2  
| loadModel3  
| loadModel4  
| loadModel5 -> rotate 0.0 45.0 90.0  
| loadModel6  
| loadModel7  
| loadModel8  
| loadModel9 -> translate 60.0 0.0 0.0 -> scale 3.0  
| loadModel10  
| loadModel11
```

Haskelyzer volá funkce na načítání a transformaci modelů. Je zapotřebí tyto funkce nadefinovat.

Haskell

```
$(generateHaskelyzerDSL "pathToHaskelyzer.haskelyzer")  
  
-- define model loading all the way to 11  
loadModel1, loadModel2 :: IO LoadedWaveFrontOBJ  
loadModel1 = parseObj "model1.obj"  
loadModel2 = parseObj "model2.obj"
```

```

rotate::
  GL.GLfloat ->
  GL.GLfloat ->
  GL.GLfloat ->
  LoadedWaveFrontOBJ
rotate degreesX degreesY degreesZ loadedWaveFront =
  let quat =
    rotateOnAxis degreesX degreesY degreesZ in
    loadedWaveFrontOBJRotation %~ ((* quat) $ loadedWaveFront

translate::
  GL.GLfloat ->
  GL.GLfloat ->
  GL.GLfloat ->
  LoadedWaveFrontOBJ
translate x y z loadedWaveFront =
  loadedWaveFront & loadedWaveFrontOBJTranslate .~ (V3 x y z)

scale::
  GL.GLfloat ->
  LoadedWaveFrontOBJ
scale x loadedWaveFront =
  loadedWaveFront & loadedWaveFrontOBJScale .~ x

```

Funkce `loadModels` vrací typ `IO [IO LoadedWaveFrontOBJ]`, což je pouze vnořená IO monáda, která se může usnadnit pomocí pomocné funkce `joinTraversableMonad` a to transformuje data do typu `IO [LoadedWaveFrontObj]`.

Haskell

```

joinTraversableMonad::
  (Monad m, Traversable t) =>
  m (t (m a)) ->
  m (t a)
joinTraversableMonad = (sequence =<<)

beforeRendering:: StateT SomeState IO ()
beforeRendering = do

```

```
-- OpenGL and it's shaders are initialized
-- and now are ready to receive data on call

models <- liftIO $ joinTraversableMonad loadModels

-- save models to state monad
modify $ \s -> s & sceneToLoad .~ models

renderFrame
```

Pomocí Haskelyzeru došlo ke splnění cíle. Konkurentně se načetly modely, kde vývojář má kontrolu nad jednotlivými vlákny. Obsah funkce `loadModels` přehledně sděluje cíl, případné modifikace jsou uživatelsky přívětivé a funkce je zapsaná v tacit formátu. Modely se načetly před renderováním prvního snímku a ty se předají do nějaké stavové monády, ze které se poté mohou modely upravovat a renderovat.

5.2 Využití pro web scraping

Haskellyzer zjednodušuje proces web scrapingu. Příkladem může být tahání dat z různých veřejných zpravodajských zdrojů a následné ukládání výsledků do databáze. Spojením s Haskellyzer, knihovnou Scalpel a jakýmkoliv databázovým systémem je možné dosáhnout rychlé sbírání dat.

Následující kód předpokládá, že jsou vytvořeny tři různé scrapery a očekávají url zdroj. Pro zjednodušení jsou zdroje zapsané ve formě

`[(String, String, String)]`, ale mohou být též v csv formátu. Cílem je dané výsledky uložit do databáze, tak je nutné vytvořit konekci k daným databázovým systémům.

Haskell

```
sourcesFromWhichToMine =
[
  ("urlToNewsSource1",
   "urlToDifferentNewsSource1",
   "urlToWeather1"
  ),
  ("urlToNewsSource2",
   "urlToDifferentNewsSource2",
   "urlToWeather2"
```

```

    ),
    ("urlToNewsSource3",
     "urlToDifferentNewsSource3",
     "urlToWeather3"
    ),
    ("urlToNewsSource4",
     "urlToDifferentNewsSource4",
     "urlToWeather4"
    ),
  ]

-- Predefine mining with algorithms here,
-- using scalpel is strongly advised
-- also define saveToPostgreSQL and saveToMongoDB
createDBConnections :: IO(MongoDBConnection,PostgreConnection)
createDBConnections = do
  x <- createMongoConnection
  y <- createPostgreConnection
  return (x, y)

```

Dalším krokem je definice způsobu scrapingu.

Haskelyzer

```

let scrapeData a b c postgresConnection mongoConnection =
  | scrapeNewsSource a -> saveToPostgreSQL postgresConnection
  | scrapeDifferentNewsSource b -> saveToMongoDB mongoConnection
  | scrapeDifferentNewsSource b -> saveToPostgreSQL mongoConnection
  | scrapeWeatherSource c -> saveToPostgreSQL postgresConnection

```

Po úspěšném scrapingu se uloží výsledky do specifikované databáze.

Haskell

```

scrapeData ::
  String ->
  String ->

```

```

String ->
PostgreConnection ->
MongoDBConnection ->
IO([IO (Bool)]) -- Bool shows if operation was successfull

-- Predefine mining with algorithms here,
-- using scalpel lib is strongly advised
-- also define saveToPostgreSQL and saveToMongoDB

$(generateHaskelyzerDSL "pathToFileMentionedAbove")

beginScraping :: IO ()
beginScraping = do
    (mongoConnection, postgresConnection) <- createDBConnections
    -- Fire mining, you can potentially wrap this
    -- into Writer monad to get useful logs
    mapM_
        (\(a,b,c) ->
            scrapeData a b c mongoConnection postgresConnection
        )
        sourcesFromWhichToMine <&> sequence . concat

```

5.3 Využití pro datovou analytiku a změření výkonu

Zpracování dat může zabrat spoustu času, jelikož většinou jednotlivé úpravy nad daty běží na jednom vlákně. Cílem je zjistit zdali clusterování dat pomocí Haskelyzeru bude rychlejší než clusterování na jednom vlákně. Příklad clusteruje 64-dimenzionální data a clusteruje od 2 až po 64 clusterů. Pro Haskelyzer se rozdělí počet clusterů podle počtu dostupných vláken.

Kód se nachází ve veřejném repositáři. (Musijenko, [2023](#))

Překvapivě bylo zjištěno, že jednovláknová implementace clusterovacího algoritmu dosahuje přibližně stonásobně vyšší výkon v porovnání s vícevláknovou variantou. Tento výsledek vyvolává otázky o optimálnosti paralelního zpracování v rámci dané úlohy a použité implementace. Jedním z potenciálních důvodů je, že vytvoření nového procesu na každém vlákně dodává výkonovou zátěž a tím se zvyšuje čas pro uskutečnění operace. Proto je vždy důležité změřit, zda-li má smysl přidat pro problém více vláken.

Obrázek 5.1: Výsledky benchmarkingu, kde jedno vlákno je rychlejší

```

Registering library for kmeans-haskellyzer-0.1.0.0..
"parsed"
benchmarking singleThreadBenchmark
time                143.7 ns    (142.7 ns .. 144.4 ns)
                    1.000 R²    (0.999 R² .. 1.000 R²)
mean                144.1 ns    (143.5 ns .. 145.0 ns)
std dev             2.737 ns    (2.203 ns .. 3.929 ns)
variance introduced by outliers: 25% (moderately inflated)

benchmarking concurrentBenchmark
time                89.98 µs    (89.32 µs .. 90.69 µs)
                    0.999 R²    (0.999 R² .. 1.000 R²)
mean                89.41 µs    (88.88 µs .. 89.89 µs)
std dev             1.918 µs    (1.579 µs .. 2.422 µs)
variance introduced by outliers: 17% (moderately inflated)

```

5.4 Nedostatky a potenciální vylepšení do budoucna

Do Haskelyzeru byla přidána funkcionální na načítání CSV souborů, kde probíhá validace s možností vkládání dat do programu. Tato funkcionální nebyla řádně testována, ale nabízí zjednodušení zpracování dat. Tato funkcionální se může rozšířit při přidání dalších parserů s případnou podporou pro SQL-NOSQL.

Potenciálním vylepšením by bylo ponechání threadů, které by byly znovu využity. V aplikaci na načítání modelů do scén se nachází pouze část, kdy se scéna načte pouze jednou. Ale co se má dít v případě, kdy se modely musí načítat postupně? Nyní se pokaždé vytvoří nový thread a právě tvorba nového threadu zabírá spoustu času, což bylo možné si povšimnout v třetím příkladu na datovou analytiku.

Nyní Haskelyzer nepodporuje obyčejné konstanty jako argumenty a spoléhá na konstanty, které musí místo toho nabízet daný modul, kde je Haskelyzer vyvolán. Těž zde chybí základní podpora foldingu pro sbírání výsledků z Haskelyzeru.

6 Závěr

Hlavním cílem této práce bylo vytvoření doménově specifického jazyka (DSL) se zaměřením na tacit (beztečkovou) syntaxi a jak je takový DSL navržen, pomocí programovacího jazyka Haskell, s ověřením použitelnosti a funkčnosti v různých aplikacích.

V první kapitole je popsáno, co vůbec takový tacit zápis je, v jakém kontextu se dá tacit syntaxe využít a naopak kdy se tomu radši vyhnout a jak je podporovaný napříč populárními programovacími jazyky, jako je Haskell nebo Javascript. Následně se provádí rešerše nad APL což je programovací jazyk, který je primárně navržen pro tacit zápis.

V druhé kapitole se nachází definice DSL a využití různých DSL ve specifických doménách problematiky.

V třetí kapitole se nachází implementace navrženého DSL, Haskelyzeru, který řeší problém domény konkurence. Jednotlivé sekce obsahují popis navrženého parseru, lexeru a jak se abstraktní syntaktický strom převádí do Haskell kódu během kompilace projektu, pomocí meta-programming mechanismu Template Haskell.

V poslední kapitole se ověřuje použitelnost navrženého DSL v grafické aplikaci s kontextem načítání modelů do scén, web scraping aplikaci pro scrapování několika web domén současně a datové analýze, kde se provádí clustering a zároveň se měří výkon DSL. Na konci jsou předneseny nedostatky Haskelyzeru a potenciální zlepšení do budoucna.

Veškeré přednesené charakteristiky a informace o tvorbě DSL v této bakalářské práci mohou sloužit jako základ pro tvorbu jakéhokoliv DSL v programovacím jazyce Haskell.

7 Citace

- FEDERICO, Tomasetti, 2021. *Domain Specific Languages* [online]. Itálie, Strumenta S.R.L. [cit. 2024-02-11]. Dostupné z: <https://tomasetti.me/domain-specific-languages/>.
- FOWLER, Martin; PARSONS, Rebecca, c2011. *Domain-specific languages*. 1. vyd. Upper Saddle River: Addison-Wesley. ISBN 03-217-1294-3.
- KANTOR, Ilya, 2019. *Currying partials* [online]. [cit. 2024-02-11]. Dostupné z: <https://javascript.info/currying-partial>.
- LATTNER, Chris, 2008. *Intro to LLVM* [online]. Erice, Sicily: Chris Lattner [cit. 2024-02-11]. Dostupné z: <https://llvm.org/pubs/2008-10-04-ACAT-LLVM-Intro.pdf>.
- MUSIJENKO, Oleg, 2023. *Clustering using Haskelyzer* [online]. Github [cit. 2024-02-11]. Dostupné z: <https://github.com/Poselsky/haskell-clustering-example>.
- SERRÃO, Rodrigo Girão, 2022. *Why APL is a language worth knowing* [online]. [cit. 2024-02-11]. Dostupné z: <https://mathspp.com/blog/why-apl-is-a-language-worth-knowing>.
- TIŠNOVSKÝ, Pavel, 2022. *Jazyk APL, kombinatory, vláčky a point-free style* [online]. [cit. 2024-02-11]. Dostupné z: <https://www.root.cz/clanky/jazyk-apl-kombinatory-vlacky-a-point-free-style>.
- TOAL, Ray, 2008. *Programming Paradigms* [online]. [cit. 2024-02-11]. Dostupné z: <https://cs.lmu.edu/~ray/notes/paradigms>.